

Determinantes Físico-Químicos da Qualidade do Vinho: Uma Análise Exploratória Comparativa entre Vinhos Tinto e Branco *Vinho Verde*

1st Iuri Fernandes
DETI
UFC
Fortaleza, Brasil
iuriferbastos@gmail.com

2nd Jonas Albuquerque
DETI
UFC
Fortaleza, Brasil
jonasalbuquerque@alu.ufc.br

3rd Joao Otavio Brasil
DETI
UFC
Fortaleza, Brasil
otavio.brasil@alu.ufc.br

Resumo—Este artigo apresenta uma análise exploratória de dados do conjunto *Wine Quality* (UCI Machine Learning Repository), composto por medições físico-químicas de amostras de vinho tinto ($N = 1599$) e branco ($N = 4898$) do tipo *Vinho Verde*, produzidos no norte de Portugal. A nota de qualidade sensorial foi discretizada em três classes (baixa, média e alta), analisadas separadamente para cada tipo de vinho. Foram realizadas análises univariadas incondicionais e condicionais à classe (média, desvio padrão, assimetria, histogramas e box-plots) dos $D = 11$ preditores físico-químicos, análise bivariada por meio de *scatter plots* e correlação de Pearson, e análise multivariada via uma implementação própria (do zero) de Análise de Componentes Principais (PCA), retraindo as duas primeiras componentes. Os resultados mostram que o teor alcoólico (*alcohol*) é o preditor discriminativo mais consistente entre os dois tipos de vinho, separando principalmente as amostras de alta qualidade das demais, enquanto as classes baixa e média permanecem praticamente indistinguíveis em suas distribuições univariadas. A estrutura de correlação difere marcadamente entre os tipos de vinho: variáveis relacionadas à acidez dominam a covariância no vinho tinto, enquanto um eixo de açúcar-densidade-álcool domina no vinho branco. Essa assimetria se reflete nos *loadings* da PCA e resulta em separabilidade limitada das classes na projeção bidimensional para ambos os vinhos (menos da metade da variância total explicada), particularmente no vinho branco.

Index Terms—qualidade do vinho, análise exploratória de dados, PCA, propriedades físico-químicas

I. INTRODUÇÃO

A qualidade do vinho tem sido tradicionalmente avaliada por meio de degustação sensorial realizada por especialistas humanos, um processo subjetivo, demorado e caro de escalar em um contexto industrial de certificação. Como as propriedades físico-químicas do vinho (acidez, teor de açúcar, teor alcoólico, concentração de dióxido de enxofre, entre outras) podem ser medidas objetivamente por meio de testes laboratoriais, uma questão natural é se essas propriedades mensuráveis conseguem explicar, ou até prever, a qualidade sensorial atribuída a um vinho. Essa questão foi abordada sistematicamente pela primeira vez por Cortez et al. [1], que introduziram os conjuntos de dados de vinho tinto e branco *Vinho Verde* utilizados neste trabalho e aplicaram técnicas de

mineração de dados para modelar preferências de vinho a partir de testes físico-químicos.

Além da modelagem preditiva, entender *quais* variáveis físico-químicas estão associadas à qualidade, e *como* elas se relacionam entre si, é uma etapa preliminar necessária antes da construção de qualquer modelo de classificação ou regressão. A Análise Exploratória de Dados (EDA) – examinando distribuições, detectando outliers, quantificando dependência linear entre preditores e inspecionando a separabilidade de classes em dimensionalidade reduzida – fornece essa compreensão e orienta escolhas de modelagem subsequentes, como seleção de atributos ou a necessidade de métodos não-lineares. Trabalhos mais recentes sobre esse mesmo conjunto de dados, como Zaza et al. [2], mostraram, por meio de análise de importância de atributos, que o teor alcoólico tem efeito significativo na qualidade prevista do vinho, achado que este artigo revisita e contextualiza por meio de estatísticas puramente descritivas, em vez de um modelo treinado.

Este artigo contribui com uma EDA do conjunto *Wine Quality* com um enfoque explicitamente *comparativo*: em vez de unir as amostras de vinho tinto e branco, ou focar em apenas um tipo, analisamos os dois tipos de vinho de forma independente e lado a lado, em todas as etapas do pipeline (análise univariada, bivariada e multivariada). Essa escolha metodológica permite perguntar não apenas “quais preditores discriminam a qualidade do vinho”, mas também “os mesmos preditores discriminam a qualidade da mesma forma nos dois tipos de vinho”. Como mostramos na Seção III, a resposta é majoritariamente negativa: os eixos físico-químicos dominantes de variação, e os preditores individuais com poder discriminativo, diferem substancialmente entre vinho tinto e branco.

O restante deste artigo está organizado da seguinte forma. A Seção II descreve o conjunto de dados, o esquema de discretização de classes e os métodos analíticos utilizados, incluindo nossa implementação própria de PCA. A Seção III apresenta e discute os resultados das análises univariada, bivariada e multivariada para os dois tipos de vinho. A Seção IV sintetiza a comparação entre vinho tinto e branco e discute

limitações da abordagem.

II. MÉTODOS

A. Descrição do conjunto de dados

Os dados utilizados neste estudo provêm do UCI Machine Learning Repository [1] e consistem em duas amostras independentes de vinho *Vinho Verde* português: vinho tinto ($N_{\text{tinto}} = 1599$) e vinho branco ($N_{\text{branco}} = 4898$). Cada observação é descrita por $D = 11$ preditores físico-químicos contínuos: acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e teor alcoólico. A variável de saída original, *quality*, é uma nota sensorial inteira atribuída por especialistas (nominalmente entre 0 e 10, embora os valores observados nas duas amostras variem de 3 a 9).

Como o objetivo deste trabalho é investigar a separabilidade de classes em relação à qualidade do vinho, a variável *quality* foi discretizada em $L = 3$ classes: *baixa* (≤ 4), *média* (5–6) e *alta* (≥ 7). Essa discretização foi aplicada de forma independente às amostras de tinto e branco, e os dois tipos de vinho foram analisados separadamente ao longo de todo o artigo, permitindo comparação direta dos padrões observados em cada um. A Tabela I mostra a distribuição de classes resultante, que é marcadamente desbalanceada em ambos os casos – consistente com a descrição original do conjunto de dados [1], que observa que vinhos comuns superam em muito os excelentes ou ruins.

Tabela I
DISTRIBUIÇÃO DE CLASSES (QUALITY DISCRETIZADA)

Classe	Tinto ($N = 1599$)		Branco ($N = 4898$)	
	N_l	%	N_l	%
Baixa	63	3,9%	183	3,7%
Média	1319	82,5%	3655	74,6%
Alta	217	13,6%	1060	21,6%

B. Análise univariada incondicional e condicional à classe

Para cada um dos $D = 11$ preditores, calculamos a média μ_d , o desvio padrão σ_d e a assimetria (*skewness*) γ_d de forma incondicional (usando todas as N observações) e condicional à classe ($\mu_{d|l}$, $\sigma_{d|l}$, $\gamma_{d|l}$, usando apenas as N_l observações da classe l). Histogramas e box-plots foram produzidos tanto para o caso incondicional quanto para o condicional à classe. Todas as estatísticas foram calculadas com *numpy/scipy*; o código completo está disponível no repositório do projeto (ver seção de Reprodutibilidade).

C. Análise bivariada

Para investigar relações entre pares de preditores, geramos *scatter plots* para todos os $\binom{11}{2} = 55$ pares de preditores, coloridos por classe. Adicionalmente, calculamos a matriz de correlação de Pearson ρ entre os D preditores, $\rho_{d_i, d_j} = \text{cov}(X_{d_i}, X_{d_j}) / (\sigma_{d_i} \sigma_{d_j})$, para quantificar a dependência linear.

D. Análise de Componentes Principais (implementação própria)

A PCA foi implementada sem o uso de bibliotecas prontas de redução de dimensionalidade, seguindo cinco passos: (i) padronização dos preditores (média zero, variância unitária), necessária dada a diferença de escala entre as variáveis (ex.: *density* $\approx 0,99$ – $1,00$ contra *total sulfur dioxide*, na casa das dezenas a centenas); (ii) cálculo da matriz de covariância $D \times D$ dos dados padronizados; (iii) autodecomposição dessa matriz via *numpy.linalg.eigh*, apropriada para matrizes simétricas; (iv) ordenação decrescente dos autovalores (e autovetores correspondentes); (v) projeção dos dados padronizados nos dois autovetores associados aos dois maiores autovalores, retidos para fins de visualização.

III. RESULTADOS

A. Análise univariada

A Tabela II reporta a média, o desvio padrão e a assimetria incondicionais para todos os $D = 11$ preditores, para os dois tipos de vinho. Diversos preditores exibem forte assimetria positiva em ambos os vinhos – destacam-se *chlorides* ($\gamma \approx 5,7$ no tinto, $5,0$ no branco) e *residual sugar* ($\gamma \approx 4,5$ no tinto, $1,1$ no branco) – indicando distribuições de cauda longa com uma pequena quantidade de outliers de valor alto, consistente com os outliers visíveis nos box-plots correspondentes (ex.: Fig. 3, painel direito).

Tabela II
ESTATÍSTICAS INCONDICIONAIS POR PREDITOR (MÉDIA / DESVIO PADRÃO / ASSIMETRIA)

Preditor	Tinto	Branco
Fixed acidity	8,32 / 1,74 / 0,98	6,85 / 0,84 / 0,65
Volatile acidity	0,53 / 0,18 / 0,67	0,28 / 0,10 / 1,58
Citric acid	0,27 / 0,19 / 0,32	0,33 / 0,12 / 1,28
Residual sugar	2,54 / 1,41 / 4,54	6,39 / 5,07 / 1,08
Chlorides	0,09 / 0,05 / 5,68	0,05 / 0,02 / 5,02
Free sulfur dioxide	15,87 / 10,46 / 1,25	35,31 / 17,01 / 1,41
Total sulfur dioxide	46,47 / 32,90 / 1,51	138,36 / 42,50 / 0,39
Density	0,9967 / 0,0019 / 0,07	0,9940 / 0,0030 / 0,98
pH	3,31 / 0,15 / 0,19	3,19 / 0,15 / 0,46
Sulphates	0,66 / 0,17 / 2,43	0,49 / 0,11 / 0,98
Alcohol	10,42 / 1,07 / 0,86	10,51 / 1,23 / 0,49

As estatísticas condicionais à classe (Tabela III) revelam preditores com tendência monotônica clara entre as classes baixa/média/alta – candidatos a preditores individualmente discriminativos. No **vinho tinto**, *alcohol* aumenta monotonicamente ($10,22 \rightarrow 10,25 \rightarrow 11,52$), *volatile acidity* diminui monotonicamente ($0,72 \rightarrow 0,54 \rightarrow 0,41$), e *citric acid* e *sulphates* aumentam monotonicamente. No **vinho branco**, *alcohol* apresenta a mesma tendência de aumento ($10,17 \rightarrow 10,27 \rightarrow 11,42$), mas os preditores relacionados à acidez que discriminam as classes no tinto – em especial *citric acid* – não mostram tendência clara; em vez disso, *chlorides* e *fixed acidity* diminuem monotonicamente com a qualidade.

As Figs. 1–4 ilustram os histogramas e box-plots condicionais à classe para dois preditores representativos. Para

Tabela III
MÉDIAS CONDICIONAIS DE PREDITORES DISCRIMINATIVOS
SELECIONADOS

Vinho	Preditor	Baixa	Média	Alta
Tinto	Alcohol	10,22	10,25	11,52
	Volatile acidity	0,72	0,54	0,41
	Citric acid	0,17	0,26	0,38
	Sulphates	0,59	0,65	0,74
Branco	Alcohol	10,17	10,27	11,42
	Chlorides	0,051	0,048	0,038
	Fixed acidity	7,18	6,88	6,73
	Sulphates	0,48	0,49	0,50

alcohol (Figs. 1, 2), as classes baixa e média estão quase inteiramente sobrepostas nos dois tipos de vinho, e apenas a classe alta se desloca visivelmente para a direita; isso indica que, apesar da tendência monotônica nas médias, o teor alcoólico *isoladamente* separa principalmente vinhos de alta qualidade dos demais, em vez de discriminar as três classes. Para *citric acid* (Figs. 3, 4), o padrão difere fortemente entre os tipos de vinho: no vinho tinto as três distribuições de classe estão visivelmente deslocadas entre si (mediana de *citric acid* $\approx 0,08$ para baixa, 0,24 para média, 0,39 para alta), enquanto no vinho branco as três distribuições são quase indistinguíveis (mediana $\approx 0,30$ nas três classes). Este é o exemplo mais claro, entre os preditores inspecionados, de uma variável com poder discriminativo em um tipo de vinho mas não no outro.




Figura 1. Histograma e box-plot condicionais à classe do preditor alcohol, vinho tinto.




Figura 2. Histograma e box-plot condicionais à classe do preditor alcohol, vinho branco.

B. Análise bivariada

A Tabela IV lista as correlações de Pearson mais fortes para cada tipo de vinho. No **vinho tinto**, as correlações dominantes envolvem variáveis relacionadas à acidez: *fixed acidity*




Figura 3. Histograma e box-plot condicionais à classe do preditor citric acid, vinho tinto.




Figura 4. Histograma e box-plot condicionais à classe do preditor citric acid, vinho branco.

correlaciona-se fortemente com *pH* ($\rho = -0,68$), *citric acid* ($\rho = 0,67$) e *density* ($\rho = 0,67$); *citric acid* e *volatile acidity* também são fortemente anticorrelacionados ($\rho = -0,55$). No **vinho branco**, em contraste, as correlações dominantes envolvem açúcar, densidade e álcool: *density* correlaciona-se muito fortemente com *residual sugar* ($\rho = 0,84$) e *alcohol* ($\rho = -0,78$), refletindo o fato físico de que o açúcar aumenta e o álcool diminui a densidade do líquido. O par dióxido de enxofre livre/total é moderadamente correlacionado nos dois tipos de vinho ($\rho \approx 0,62-0,67$), como esperado, já que o SO_2 livre é um subconjunto do SO_2 total.

Tabela IV
CORRELAÇÕES DE PEARSON MAIS FORTES ENTRE PARES DE PREDITORES

Vinho	Par de preditores	ρ
Tinto	fixed acidity – pH	$-0,68$
	fixed acidity – citric acid	$0,67$
	fixed acidity – density	$0,67$
	citric acid – volatile acidity	$-0,55$
Branco	density – residual sugar	$0,84$
	density – alcohol	$-0,78$
	total SO_2 – density	$0,53$
	free SO_2 – total SO_2	$0,62$

Essa assimetria – covariância dominada pela acidez no vinho tinto versus covariância dominada por açúcar/densidade/álcool no vinho branco – não tinha razão *a priori* para aparecer, já que os dois vinhos compartilham o mesmo conjunto de $D = 11$ preditores; trata-se de um achado empírico da análise bivariada, que antecipa os resultados da PCA discutidos a seguir. As matrizes de correlação completas são mostradas como *heatmaps* nas Figs. 5 e 6.




Figura 5. Matriz de correlação de Pearson, vinho tinto.




Figura 6. Matriz de correlação de Pearson, vinho branco.

C. Análise de Componentes Principais

As duas primeiras componentes principais explicam 45,7% da variância total no vinho tinto (PC1: 28,2%, PC2: 17,5%) e 43,6% no vinho branco (PC1: 29,3%, PC2: 14,3%). Em ambos os casos, mais da metade da variância total está fora da projeção bidimensional, o que já sugere que uma visualização com duas componentes captura apenas parcialmente a estrutura dos dados.

Os *loadings* das duas primeiras componentes (Tabela V) refletem a assimetria encontrada na análise bivariada. No **vinho tinto**, a PC1 é dominada por *fixed acidity* (−0,49), *citric acid* (−0,46), *density* (−0,40) e *pH* (0,44), formando o que pode ser interpretado como um *eixo de acidez*; a

PC2 é dominada por *total sulfur dioxide* (0,57) e *free sulfur dioxide* (0,51), um *eixo de dióxido de enxofre*. No **vinho branco**, os papéis se invertem: a PC1 é dominada por *density* (0,51), *residual sugar* (0,43) e *alcohol* (−0,44), formando um *eixo de doçura/álcool*, enquanto a PC2 é dominada por *fixed acidity* (0,59) e *pH* (−0,58), um *eixo de acidez*. Em outras palavras, a mesma dimensão física (acidez) que explica a maior parte da variância no vinho tinto explica apenas a *segunda* componente no vinho branco, e vice-versa para a dimensão de açúcar/álcool.

Tabela V
LOADINGS DOMINANTES DA PCA (3 MAIORES EM MAGNITUDE)

Vinho	Preditor	PC1	PC2
Tinto	Fixed acidity	−0,49	−0,11
	Citric acid	−0,46	−0,15
	pH	0,44	0,01
Branco	Density	0,51	−0,01
	Residual sugar	0,43	−0,01
	Alcohol	−0,44	0,04

As Figs. 7 e 8 mostram a projeção das observações nas duas primeiras componentes principais, coloridas por classe. Em ambos os vinhos, as três classes se sobrepõem substancialmente, sem fronteira visível (linear ou não) separando-as; a classe média, sendo majoritária nos dois conjuntos de dados, ocupa a maior parte da região central e envolve as classes baixa e alta. Ainda assim, algumas diferenças qualitativas são visíveis: no vinho tinto, os pontos de alta qualidade se concentram de forma perceptível em valores mais baixos de PC2, gerando uma separação parcial (embora longe de limpa) em relação à classe média; no vinho branco, essa tendência não é observada, e as três classes estão essencialmente co-localizadas, à exceção de um único outlier visível na região inferior direita da projeção ($PC1 \approx 12,5$), que merece investigação adicional como possível anomalia nos dados.

IV. DISCUSSÃO

Três achados se destacam nesta análise exploratória. Primeiro, o *alcohol* é o preditor discriminativo mais consistente entre os dois tipos de vinho, mas seu poder discriminativo está concentrado na separação da classe alta em relação às demais: as distribuições condicionais das classes baixa e média se sobrepõem quase completamente nos dois vinhos (Figs. 1, 2), apesar de uma diferença mensurável nas médias. Isso é consistente com os achados de importância de atributos de Zaza et al. [2] sobre o mesmo conjunto de dados, obtidos por meio de um modelo treinado em vez de estatísticas descritivas.

Segundo, a estrutura físico-química subjacente à qualidade do vinho difere substancialmente entre tinto e branco. Variáveis relacionadas à acidez (*citric acid*, *fixed acidity*, *volatile acidity*) mostram forte poder discriminativo e dominam tanto a estrutura de correlação quanto a primeira componente principal no vinho tinto, mas são comparativamente pouco informativas no vinho branco, onde *chlorides*




Figura 7. Projeção nas duas primeiras componentes principais, vinho tinto, colorida por classe.




Figura 8. Projeção nas duas primeiras componentes principais, vinho branco, colorida por classe.

e o eixo açúcar/densidade/álcool desempenham papel mais proeminente. Essa assimetria sustenta a escolha metodológica, adotada neste trabalho, de analisar os dois tipos de vinho separadamente em vez de agrupá-los em um único conjunto de dados com o tipo de vinho como preditor adicional.

Terceiro, a separabilidade de classes na projeção PCA de duas componentes é fraca para os dois tipos de vinho, e ainda mais fraca no vinho branco. Isso é esperado por pelo menos dois motivos: a PCA é uma técnica não supervisionada e linear que maximiza variância sem usar os rótulos de classe, de modo que só revela estrutura de classes se essa estrutura coincidir com as direções de maior variância; e, com menos da metade da variância total capturada pelas duas primeiras

componentes em qualquer um dos vinhos, uma parcela substancial da informação relevante para a separação de classes provavelmente está nas componentes restantes. Isso sugere que técnicas não-lineares de redução de dimensionalidade, ou seleção supervisionada de atributos informada pelos achados univariados da Seção III, seriam passos naturais seguintes para a construção de um modelo preditivo, embora tal modelagem esteja fora do escopo desta análise exploratória.

Uma limitação do esquema de discretização adotado aqui (baixa/média/alta) é o forte desbalanceamento de classes em ambos os tipos de vinho (Tabela I), particularmente na classe baixa (63 e 183 observações para tinto e branco, respectivamente); estatísticas calculadas sobre a classe baixa, incluindo a assimetria, devem ser interpretadas com cautela adicional dado o tamanho reduzido da amostra.

REPRODUTIBILIDADE

Todo o código utilizado para produzir as estatísticas, figuras e resultados de PCA reportados neste artigo está disponível no repositório Git do projeto, junto com instruções para reproduzir a análise a partir dos arquivos originais do conjunto de dados da UCI.

REFERÊNCIAS

- [1] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis, "Modeling wine preferences by data mining from physicochemical properties," *Decision Support Systems*, vol. 47, no. 4, pp. 547–553, 2009.
- [2] S. Zaza, M. Atemkeng, and S. Hamlomo, "Wine feature importance and quality prediction: A comparative study of machine learning algorithms with unbalanced data," in *Safe, Secure, Ethical, Responsible Technologies and Emerging Applications (SAFER-TEA 2023)*, Lecture Notes of the Institute for Computer Sciences, Social Informatics and Telecommunications Engineering, vol. 566, Cham: Springer, 2024, pp. 27–33.